강의계획서

딥러닝 자연어처리

부제: LLM 시대의 NLP 엔지니어링: 원리부터 배포까지

---

1. 교과목 기본 정보

항목	내용
교과목명	딥러닝 자연어처리
학수번호	—
학점	3학점
수업 시수	주 2회 × 90분 (A회차 + B회차)
수업 방식	이론 강의 + 라이브 코딩 + 실습
개설 학기	2026년 1학기
대상 학년	2~4학년
담당 교수	이석민

---

2. 교과목 개요

본 과목은 딥러닝 기반 자연어처리(NLP)의 핵심 원리를 체계적으로 학습하고, 대규모 언어 모델(LLM)을 실무에 활용할 수 있는 역량을 기르는 것을 목적으로 한다. 신경망 기초부터 시작하여 Transformer 아키텍처, BERT/GPT 계열 모델, 파인튜닝, RAG, AI Agent, 모델 배포까지 현업에서 즉시 적용 가능한 기술을 단계적으로 다룬다.

---

3. 학습 목표

1. 딥러닝 신경망의 핵심 원리(역전파, 경사 하강법)를 이해하고 PyTorch로 구현할 수 있다.
2. Transformer 아키텍처의 Self-Attention, Multi-Head Attention, Positional Encoding을 구현하고 원리를 설명할 수 있다.
3. BERT, GPT 계열 사전학습 모델의 구조와 특성을 비교하고, Hugging Face 생태계를 능숙하게 활용할 수 있다.
4. LLM API 호출, 프롬프트 엔지니어링, Function Calling을 활용하여 AI 응용 시스템을 개발할 수 있다.
5. Full Fine-tuning, LoRA/QLoRA 등 파인튜닝 기법을 선택하고 적용할 수 있다.
6. RAG 파이프라인과 AI Agent를 설계하고 배포할 수 있다.

---

4. 강의 구성 철학

기초 압축 (4주) → LLM 핵심 (2주) → 중간고사 → 실무 기술 (5주) → 프로젝트 (2주) → 기말고사

- **기초는 빠르게, 실무는 깊게**: RNN은 개념 중심, Transformer부터 본격 구현
- **밑바닥 구현 → 프레임워크 활용**: 원리를 먼저 이해한 뒤 도구를 활용한다
- **취업 직결 기술 우선**: Agent, 배포, 평가 등 현업 필수 스킬 포함
- **직관 먼저, 수식 다음**: 모든 개념을 비유와 시각화로 먼저 이해하고, 이후 수학적 정의로 넘어간다

---

5. 실습 환경

항목	내용
IDE	VS Code 1.102+
AI 보조 도구	GitHub Copilot Pro (학생 무료)
언어 / 프레임워크	Python 3.10+ / PyTorch 2.x
라이브러리	Hugging Face Transformers, PEFT, LangChain 등
GPU 환경	CUDA 지원 GPU 권장 (없는 경우 Google Colab 활용)

Copilot 활용 원칙: A회차(이론)에서는 원리를 직접 학습하고, B회차(실습)에서 Copilot을 활용하여 구현을 가속화한다. Copilot은 주 작성자가 아닌 구현 보조 도구로 활용한다.

---

6. 수업 운영 구조

매주 2회 수업을 A회차(이론·시연)와 B회차(실습·토론)로 운영한다.

A회차 (90분) — 이론 + 라이브 코딩

시간	내용
00:00~00:05	오늘의 질문 + 진단 퀴즈 (1문항)
00:05~00:55	이론 강의 (직관적 비유 → 개념 → 원리 → 수식)
00:55~01:25	라이브 코딩 시연 (교수 주도)
01:25~01:28	핵심 정리 + B회차 과제 스펙 공개
01:28~01:30	Exit Ticket (1문항)

B회차 (90분) — 실습 + 토론

시간	내용
00:00~00:05	2인1조 편성 + 과제 스펙 확인
00:05~00:10	A회차 핵심 코드 리캡 + Copilot 활용 가이드
00:10~00:55	Copilot 활용 조별 구현 (체크포인트 3개)
00:55~01:00	Google Classroom 제출 (코드 + 결과 + 해석)
01:00~01:20	조별 결과 공유 + 전체 토론
01:20~01:28	교수 종합 피드백 + 모범 구현 비교
01:28~01:30	다음 주 예고

7. 주차별 강의 계획

주차	A회차 (이론 + 시연)	B회차 (실습 + 토론)	B회차 과제
1	AI 시대의 개막 + PyTorch 기초	환경 구축 + Tensor 실습	GPU 환경 구축 + Tensor 과제
2	신경망 핵심 원리 + PyTorch 패턴	MLP 텍스트 분류 구현 + 성능 비교	IMDb 감성 분류 MLP + 분석
3	임베딩 + RNN → Attention 원리	Self-Attention 구현 + 시각화	Attention 모듈 구현 + 시각화 리포트
4	Transformer 아키텍처 심층 분석	Transformer Encoder 분류기 구현	Transformer Encoder 텍스트 분류
5	BERT vs GPT 아키텍처 비교	BERT/GPT 활용 실습 + 성능 비교	BERT NER + GPT-2 텍스트 생성기
6	프롬프트 엔지니어링 + API 활용	API 활용 시스템 구축 + 전략 토론	도메인 특화 텍스트 분석 시스템
7	**중간고사 대비 (1~6주차 복습)**	**중간고사 (객관식, 80분)**	—
8	토픽 모델링 이론 + BERTopic 시연	BERTopic 실습 + 결과 해석 토론	토픽 모델링 분석 보고서
9	Full Fine-tuning 원리 + Trainer 시연	BERT 파인튜닝 실습 + 학습 전략 토론	전공 분야 모델 파인튜닝
10	PEFT/LoRA 원리 + QLoRA 시연	LoRA 실습 + Full FT 비교 토론	LoRA vs Full FT 비교 보고서
11	RAG 아키텍처 설계 + 파이프라인 시연	RAG Q&A 시스템 구축 + 검색 전략 토론	전공 문서 기반 RAG Q&A 시스템
12	AI Agent 개념 + LangGraph 시연	Agent 프로토타입 개발 + 설계 토론	도메인 특화 AI Agent
13	모델 배포 + 최적화 시연	FastAPI 배포 + 평가 실습 + 토론	FastAPI 배포 + 평가 리포트
14	개인 프로젝트 워크숍 A	개인 프로젝트 워크숍 B	프로토타입 완성
15	**개인 프로젝트 최종 발표**	**기말고사 (객관식)**	—

8. 주차별 세부 내용

1주차: AI 시대의 개막과 개발 환경 구축
미션: 수업이 끝나면 PyTorch로 첫 번째 딥러닝 모델을 실행한다.

A회차 주요 내용 - AI, 머신러닝, 딥러닝의 관계와 NLP 응용 분야 - 언어 모델의 발전사: 통계 → 신경망 → Transformer → LLM - 개발 환경 자동 구축 (`scripts/setup_env.py`) - Python/PyTorch 기초: Tensor 연산과 Autograd 자동 미분

B회차 실습 - GPU 환경 구축 및 검증 (CPU vs GPU 벤치마크) - GitHub Copilot Pro 설정 - PyTorch Tensor 연산 실습 (GPU 이동 포함) - 간단한 선형 회귀 모델 구현

2주차: 딥러닝 핵심 원리와 PyTorch 실전
미션: 수업이 끝나면 텍스트 분류 모델을 직접 학습시킨다.

A회차 주요 내용 - 퍼셉트론 → MLP: 비선형 활성화 함수(ReLU, GELU, Softmax) - 손실 함수(Cross-Entropy), 경사 하강법, 역전파 - `nn.Module` 기반 모델 정의, `Dataset/DataLoader` 구성 - 옵티마이저(SGD, Adam, AdamW), 학습률 스케줄러 - Training/Validation Loop, 과적합 방지(Dropout, Weight Decay)

B회차 실습 - 텍스트 전처리(토큰화, BoW, TF-IDF) - MLP 기반 감성 분석 모델 구현 및 하이퍼파라미터 실험

3주차: 시퀀스 모델에서 Transformer로
미션: 수업이 끝나면 Attention이 문장의 어디에 집중하는지 시각화한다.

A회차 주요 내용 - Word2Vec(CBOW/Skip-gram), 사전학습 임베딩(GloVe, FastText) - RNN/LSTM/GRU: 장기 의존성 문제와 게이트 메커니즘 (개념 중심) - Seq2Seq + Encoder-Decoder 구조 - Scaled Dot-Product Attention: Q, K, V의 직관과 수식 - Self-Attention, Multi-Head Attention

B회차 실습 - Word2Vec 모델 로드 및 유사도 측정 - Self-Attention 메커니즘 단계별 구현 - Attention Weights 시각화

4주차: Transformer 아키텍처 심층 분석
미션: 수업이 끝나면 Transformer Encoder를 밑바닥부터 구현한다.

A회차 주요 내용 - "Attention is All You Need" 핵심 기여 - Encoder 구조: Self-Attention + FFN + Residual + LayerNorm - Decoder 구조: Masked Self-Attention + Cross-Attention - Positional Encoding (Sinusoidal vs Learned) - BPE, WordPiece, SentencePiece Tokenization

B회차 실습 - Transformer Encoder Block 밑바닥 구현 - Positional Encoding 구현 및 시각화 - Transformer 기반 텍스트 분류기 구현

5주차: LLM 아키텍처 — BERT와 GPT
미션: 수업이 끝나면 BERT와 GPT를 직접 돌려보고 차이를 체감한다.

A회차 주요 내용 - Pre-training → Fine-tuning 패러다임, Transfer Learning - Encoder-only vs Decoder-only vs Encoder-Decoder 설계 철학 - BERT: MLM + NSP, 양방향 문맥, 변형 모델(RoBERTa, DistilBERT 등) - GPT: Autoregressive LM, Causal Self-Attention, 스케일링의 원리 - 텍스트 생성 전략: Greedy, Beam Search, Top-k/Top-p, Temperature - Hugging Face Pipeline API, AutoModel, GPU 가속 추론

B회차 실습 - BERT Tokenizer, 임베딩 추출, NER 수행 - GPT-2 텍스트 생성 + 디코딩 전략 비교 실험

6주차: LLM API 활용과 프롬프트 엔지니어링
미션: 수업이 끝나면 LLM API로 나만의 AI 앱 프로토타입을 만든다.

A회차 주요 내용 - 상용 LLM API 생태계: OpenAI, Anthropic, Google Gemini, 오픈소스 LLM - API Key 관리, 토큰 단위 비용, Rate Limiting - 프롬프트 엔지니어링: Zero-shot, Few-shot, Chain-of-Thought, System Prompt - Structured Output, Function Calling, Tool Use 패턴 - LLM 평가: Perplexity, BLEU/ROUGE, LLM-as-a-Judge, Hallucination 탐지

B회차 실습 - OpenAI / Claude API 호출 및 응답 처리 - 프롬프팅 기법 비교 실험 - Function Calling으로 외부 도구 연동

7주차: 토픽 모델링 — 텍스트 속 숨겨진 주제 찾기
미션: 수업이 끝나면 뉴스 기사 수만 건에서 숨겨진 주제를 자동으로 찾아낸다.

A회차 주요 내용 - LDA(Latent Dirichlet Allocation)의 확률론적 접근 - BERTopic: 문서 임베딩 + UMAP(차원 축소) + HDBSCAN(클러스터링) + c-TF-IDF - Hierarchical Topic Clustering, Dynamic Topic Modeling

B회차 실습 - 실제 뉴스 데이터 로드 및 전처리 - BERTopic 모델 생성 및 학습 - 주제 시각화(barchart, heatmap, network) + 시계열 트렌드 분석

8주차: 중간고사

A회차	중간고사 대비 — 1~6주차 이론 복습 + 구현 패턴 정리
B회차	**중간고사 실시** (객관식, 80분, 교재·인터넷·Copilot 사용 금지)
평가 범위	신경망 원리, PyTorch 패턴, Attention/Transformer, BERT vs GPT, 프롬프트 엔지니어링

9주차: LLM 파인튜닝 (1) — Full Fine-tuning
미션: 수업이 끝나면 나만의 데이터로 BERT 모델을 파인튜닝한다.

A회차 주요 내용 - Full Fine-tuning vs PEFT 개념적 차이 - Learning Rate Warmup & Decay, 과적합 방지 - Hugging Face Trainer API: TrainingArguments, Datasets 라이브러리 - Checkpoint & Resume, 분산 학습 지원 - 평가 지표(Accuracy, F1, AUC), Confusion Matrix, 클래스 불균형 처리

B회차 실습 - Datasets로 데이터 로드 및 전처리 - Trainer로 BERT 파인튜닝 - 학습 곡선 시각화, 최적 체크포인트 선택

10주차: LLM 파인튜닝 (2) — PEFT와 LoRA
미션: 수업이 끝나면 GPU 메모리 1/10로 거대 모델을 파인튜닝한다.

A회차 주요 내용 - PEFT 개념: Adapter Layers, Prefix Tuning, Prompt Tuning - LoRA 수학: $\Delta W = AB$ (저랭크 분해), rank 선택, 파라미터 절감 효과 - QLoRA: 4-bit 양자화(NF4) + Double Quantization, bitsandbytes

B회차 실습 - PEFT 라이브러리로 LoRA 설정 및 적용 - QLoRA 환경 설정, 대형 모델(Llama, Mistral) 파인튜닝 - Full FT vs LoRA vs QLoRA 성능·메모리 비교

11주차: RAG 시스템 구축
미션: 수업이 끝나면 도메인 문서 기반 Q&A 시스템을 배포한다.

A회차 주요 내용 - RAG의 필요성: LLM 한계(학습 데이터 컷오프, 폐쇄 지식) 극복 - Document Chunking, Embedding 벡터화, Vector DB(FAISS, Chroma, Pinecone) - Retriever, Reranker, Prompt Construction, Generator - 고급 RAG: Hybrid Search, Multi-Turn, Query Expansion, Chain-of-Thought RAG

B회차 실습 - PDF/텍스트 문서 로드 및 청킹 - FAISS/Chroma 벡터 DB 구축 - LangChain으로 RAG 파이프라인 구성 및 성능 평가

12주차: AI Agent 개발
미션: 수업이 끝나면 자율적으로 태스크를 수행하는 AI Agent를 만든다.

A회차 주요 내용 - AI Agent 개념: Agentic Loop (Thought → Action → Observation) - ReAct(Reasoning + Acting) 프레임워크 - Multi-Agent 시스템, LangGraph 워크플로우 설계 - 메모리 관리(단기/장기/에피소드), 오류 복구 전략

B회차 실습 - ReAct 에이전트 구현 - LangGraph로 Multi-Agent 파이프라인 구성 - 도메인 특화 Agent 프로토타입 개발

13주차: 모델 배포와 프로덕션
미션: 수업이 끝나면 파인튜닝한 모델을 API 서버로 배포한다.

A회차 주요 내용 - 추론 최적화: Quantization(INT8/INT4), ONNX 변환, TorchScript - Model Serving: FastAPI, vLLM, TGI(Text Generation Inference) - 배포 환경: Docker 컨테이너화, HuggingFace Spaces - 모니터링: Latency, Throughput, 오류율 - 비용 최적화 및 보안 고려사항

B회차 실습 - FastAPI로 모델 추론 API 서버 구현 - Docker 컨테이너화 및 배포 - 성능 벤치마크 및 평가 리포트 작성

14주차: 개인 프로젝트 워크숍
A회차: 프로젝트 가이드라인 공유 + 개발 집중 (개별 면담 포함) **B회차**: 개발 집중 + 교수 순회 피드백 (배포 체크리스트 확인)

프로토타입 완성 요건: 코드 실행 가능, 최소 기능 구현, README 작성

15주차: 최종 평가
A회차: 개인 프로젝트 최종 발표 (1인당 5~7분 + 질의응답 3분)

발표 구성: 문제 정의 → 기술 스택 및 접근법 → 결과 및 성능 → 한계 및 개선 방향

B회차: **기말고사** (객관식, 시험 범위: 전 과목)

---

9. 평가 기준

평가 항목	비율	세부 내용
중간고사	25%	객관식, 1~6주차 범위, 80분
기말고사	25%	객관식, 전 과목 범위
B회차 과제	30%	주차별 실습 코드 + 분석 보고서 (12회)
개인 프로젝트	20%	구현 완성도, 발표, 창의성
합계	100%	

---

10. 교재 및 참고 자료

강의 교재

- 강의 노트 (Google Classroom에서 배포 — 본 과목 자체 집필 교재)

주요 참고 도서

- Vaswani et al. (2017). Attention is All You Need. NeurIPS.
- Devlin et al. (2018). BERT: Pre-training of Deep Bidirectional Transformers. NAACL.
- Brown et al. (2020). Language Models are Few-Shot Learners (GPT-3). NeurIPS.
- Hu et al. (2022). LoRA: Low-Rank Adaptation of Large Language Models. ICLR.
- Lewis et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS.

온라인 자료

- Hugging Face 공식 문서
- PyTorch 공식 튜토리얼
- The Illustrated Transformer — Jay Alammar
- LangChain 공식 문서

---

11. 수강 유의사항

1. **필수 선수 과목**: 파이썬 프로그래밍(권장이나 필수는 아님)
2. **B회차 과제 제출**: 매 B회차 수업 시간 내 Google Classroom에 코드 + 실행 결과 + 해석 제출. 반드시 해당 시간 안에 과제를 마치고 제출하도록 하고 결석자는 주말까지 가능
3. **2인1조 실습**: 매 B회차마다 조 편성. 분석·구현은 협의하되 보고서는 개별 작성
4. **AI 도구 활용**: B회차 실습에서 GitHub Copilot 적극 활용 권장. 단, 중간고사·기말고사는 사용 금지
5. **출석**: 출석 미달 시 학칙에 따라 성적 불이익 적용
6. **GPU 환경**: GPU가 없는 경우 Google Colab

---

12. 담당교수 정보

항목	내용
담당교수	이석민
Homepage	https://my-life-six-pi.vercel.app/
이메일	newmind68@hs.ac.kr
연구실	8303
상담시간	사전 예약